



# SLAM - řešerše

## Projekt 4

Jakub Kratochvíl

Akademický rok 2017/2018

# Obsah

<b>1</b>	<b>Úvod</b>	<b>2</b>
<b>2</b>	<b>SLAM</b>	<b>3</b>
<b>3</b>	<b>Pravděpodobnostní definice</b>	<b>4</b>
<b>4</b>	<b>Graph-Based SLAM</b>	<b>6</b>
4.1	Obecně . . . . .	6
4.2	Definice . . . . .	7

# 1 Úvod

SLAM je zkratka pro simultánní lokalizaci a mapování, jeden ze základních problémů autonomních robotů. Jeho řešením by měl být robot, schopný na neznámém místě v neznámém prostředí vytvořit mapu tohoto prostředí a zároveň se v ní sám během pohybu lokalizovat.

Do povědomí se SLAM dostal v roce 1986 na konferenci IEEE Robotics and Automation, která se konala v San Francisku v Kalifornii [4]. V tomto období se v robotice a umělé inteligenci začaly objevovat metody založené na pravděpodobnostních principech a tak vyvstala otázka možnosti použití odhadových metod na mapovací a lokalizační problémy. Po následujících diskuzích se problém ukázal jako velice zajímavý a konzistentní pravděpodobnostní mapování stalo jedním ze základních problémů a výzev robotiky.

Aplikací SLAM můžeme najít mnoho, počínaje autonomním domácím vysavačem nebo sekačkou na trávu přes robotický průzkum opuštěných nebo člověku nebezpečných prostor, navigaci ponorek kolem podmořských přírodních překážek, řízení bezpilotních letounů a dronů až po v poslední době hodně diskutované samořídící automobily nebo dokonce planetární rovery brázdící povrch Marsu.

Tato práce si klade za úkol čtenáře seznámit se základními vlastnostmi a popisem problému SLAM. Dává nahlédnout do jeho původní pravděpodobnostní definice a v další části se podrobněji zabývá metodou Graph SLAM.


## 2 SLAM

SLAM je problém týkající se otázky, zda je možné najít polohu nějakého zařízení vzhledem k jeho okolí a současně mapovat strukturu prostředí.

Landmarky nebo také majáky jsou nezaměnitelné a snadno rozpoznatelné orientační body v prostředí, které mohou být v některých aplikacích dopředu známy. Například autonomní vozík pohybující se ve výrobní hale může mít předem nadefinovanou mapu landmarků. Nebo robot pro práci pod širým nebem používající pro svou orientaci GNSS (globální družicový polohový systém). V takových případech, kdy lze stroj lokalizovat vzhledem ke známým bodům, nemusí být SLAM vyžadován. Ovšem v husté zástavbě, v podzemí a uvnitř budov je použití GNSS omezené nebo úplně nemožné. V neznámém prostředí zase nelze využít předem připravenou mapu a přichází nutnost použití jiného řešení, kterým bývá nejčastěji právě SLAM. Navíc v mnoha vojenských i civilních aplikacích není cílem lokalizace, ale právě robotem vytvořená mapa, kterou poté dále zpracovává lidský operátor.

Další z impulsů vývoje simultánní lokalizace a mapování byl špatný odhad pohybu získaný z odometrie kol, čímž se rozumí například počet otáček, úhel natočení apod. [3]. Tento odhad se navíc s ujetou vzdáleností zhoršuje (tzv. drift) a tím znemožňoval použití pro správnou a přesnou lokalizaci i tvorbu mapy. Nicméně dnešní algoritmy dokáží snížit drift na přijatelnou hodnotu 0,5% a méně, takže v tomto ohledu není nutno využívat SLAM.

V čem je ale stále nenahraditelný, je schopnost tzv. uzavírání smyček. Při použití dat pouze z odometrie robot vnímá svět jako "nekonečný koridor", ve kterém neustále zkoumá nové oblasti (obr.1 vlevo). SLAM ale dokáže robotem vytvořenou smyčku uzavřít, protože porovná aktuální landmarky s těmi dříve objevenými a tím dokáže správně porozumět topologii prostředí a v mapě určit, že tyto dvě chodby se protínají (obr.1 vpravo).



Obrázek 1: Levá mapa je vytvořená pomocí odometrie a znázorňuje jeden dlouhý koridor od bodu A do B. Body, které jsou ve skutečnosti blízko (B a C) mohou být podle této mapy libovolně daleko. Pravá mapa je vytvořená pomocí SLAM s využitím uzavírání smyček, kde je znázorněná správná topologie prostředí, neboť robot správně našel "zkratku" mezi dvěma koridory. [3]


SLAM je ze své podstaty problém typu slepice-vejce a je tedy do značné míry netriviální. Robot pro svoji lokalizaci potřebuje mapu terénu, avšak k sestavení mapy musí znát svou vlastní polohu. Ovšem existují algoritmy, které, i přes tento rozpor, uspokojivě fungují a nasnadě je tedy otázka "Je SLAM vyřešen?". Ano i ne, otázku je nutno položit pro konkrétní konfiguraci robota, prostředí a požadavků, kde může figurovat mnoho kombinací, např. z následujících možností.

- Robot: dynamika, maximální rychlost, dostupné senzory, výpočetní výkon
- Prostředí: 2D/3D, přírodní/umělé, přítomnost dynamických prvků, množství a typ landmarků, množství symetrie
- Požadavky: přesnost odhadu stavu robota, přesnost a typ mapy, míra úspěšnosti, latence odhadu, maximální velikost mapované oblasti...

Například mapování vnitřního 2D prostředí s robotem vybaveným snímačem kol a laserovým senzorem s dostatečnou přesností a robustností lze považovat z velké části za vyřešené. Na druhou stranu další kombinace robot/prostředí/požadavky si stále zaslouží velké množství výzkumu. Aktuální algoritmy mohou snadno selhat, jestliže je pohyb robota nebo prostředí příliš náročný.

### 3 Pravděpodobnostní definice

Uvažujme mobilního robota, který se pohybuje v neznámém prostředí a pomocí svých senzorů pořizuje relativní pozorování okolních landmarků (obr.2).



Obrázek 2: Skutečné umístění landmarků ani robota není nikdy známo, jen jejich vzájemná poloha [4].

V okamžiku  $k$  definujeme následující veličiny a zároveň vektory jejich historie od počátku snímání až do aktuálního časového kroku:

- $\mathbf{x}_k$ ;  $\mathbf{X}_{0:k} = \{x_0, x_1, \dots, x_k\} = \{\mathbf{X}_{0:k-1}, \mathbf{x}_k\}$ : Stavový vektor popisující polohu a orientaci robota, respektive historii všech jeho stavů.
- $\mathbf{u}_k$ ;  $\mathbf{U}_{0:k} = \{u_1, u_2, \dots, u_k\} = \{\mathbf{U}_{0:k-1}, \mathbf{u}_k\}$ : Vektor řízení použitý v čase  $k-1$  pro dosažení stavu  $x_k$  v čase  $k$ , resp. historie řízení.
- $\mathbf{m}_i$ ;  $\mathbf{m} = \{m_1, m_2, \dots, m_n\}$ : Vektor popisující polohu  $i$ -tého landmarku, resp. vektor popisující polohy všech landmarků.
- $\mathbf{z}_{ik}$ ;  $\mathbf{Z}_{0:k} = \{z_1, z_2, \dots, z_k\} = \{\mathbf{Z}_{0:k-1}, \mathbf{z}_k\}$ : Pozorování o poloze  $i$ -tého landmarku získané z robota, resp. soubor všech pozorování.

Skutečný robot bude vždy zatížen nějakou nepřesností použitých měřících zařízení a tak se přímo nabízí využití pravděpodobnosti pro formulaci úlohy SLAM. Tento přístup je jedním z nejběžnějších a také nejstarších. K vyřešení problému SLAM je potřeba určit sdruženou posteriorní hustotu pravděpodobnosti landmarků  $\mathbf{m}$  a stavů robota  $x_k$  pro všechny časy  $k$ .

$$p(\mathbf{x}_k, \mathbf{m} \mid \mathbf{Z}_{0:k}, \mathbf{U}_{0:k}, \mathbf{x}_0) \quad (1)$$

K výpočtu je nutno znát vektor pozorování, vektor řízení a počáteční polohu robota. Výpočet hustoty se provádí pro každý časový okamžik  $k$ . Vhodné je použít rekursivní algoritmus, který získá hustotu pravděpodobnosti v časovém okamžiku  $k$  pomocí hustoty v okamžiku  $k - 1$ .

$$p(\mathbf{x}_{k-1}, \mathbf{m} \mid \mathbf{Z}_{0:k-1}, \mathbf{U}_{0:k-1}) \quad (2)$$

Tento výpočet vyžaduje definování modelu pozorování a pohybového modelu.

1. **Model pozorování** popisuje s jakou pravděpodobností získáme pozorování  $z_k$ , pokud známe polohu robota i landmarků.

$$p(\mathbf{z}_k \mid \mathbf{x}_k, \mathbf{m}) \quad (3)$$

2. **Pohybový model** popisuje s jakou pravděpodobností se robot nachází ve stavu  $x_k$ , pokud známe předchozí stav  $x_{k-1}$  a aplikované řízení  $u_k$ .

$$p(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (4)$$

Stavový přechod pohybového modelu je Markovský proces, neboť stav  $x_k$  závisí pouze na předchozím stavu  $x_{k-1}$  a aplikovaném řízení  $u_k$  a je nezávislý na pozorováních i mapě. SLAM algoritmus je nyní implementován ve standardní dvoustupňové (predikce-korekce) rekursivní formě.

## 1. Predikce

$$p(\mathbf{x}_k, \mathbf{m} \mid \mathbf{Z}_{0:k-1}, \mathbf{U}_{0:k}, \mathbf{x}_0) = \int p(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \mathbf{u}_k) \times p(\mathbf{x}_{k-1}, \mathbf{m} \mid \mathbf{Z}_{0:k-1}, \mathbf{U}_{0:k-1}, \mathbf{x}_0) d\mathbf{x}_{k-1} \quad (5)$$

## 2. Korekce

$$p(\mathbf{x}_k, \mathbf{m} \mid \mathbf{Z}_{0:k}, \mathbf{U}_{0:k}, \mathbf{x}_0) = \frac{p(\mathbf{z}_k \mid \mathbf{x}_k, \mathbf{m}) p(\mathbf{x}_k, \mathbf{m} \mid \mathbf{Z}_{0:k-1}, \mathbf{U}_{0:k}, \mathbf{x}_0)}{p(\mathbf{z}_k \mid \mathbf{Z}_{0:k-1}, \mathbf{U}_{0:k})} \quad (6)$$

Rovnice (5) a (6) poskytují rekursivní postup pro výpočet hustoty pravděpodobnosti  $p(\mathbf{x}_k, \mathbf{m} \mid \mathbf{Z}_{0:k}, \mathbf{U}_{0:k}, \mathbf{x}_0)$  stavu robota  $\mathbf{x}_k$  a mapy  $\mathbf{m}$  v čase  $k$  na základě všech pozorování  $\mathbf{Z}_{0:k}$  a všech řízení  $\mathbf{U}_{0:k}$ .

Problém budování mapy lze formulovat jako výpočet podmíněné hustoty pravděpodobnosti  $p(\mathbf{m} \mid \mathbf{X}_{0:k}, \mathbf{Z}_{0:k}, \mathbf{U}_{0:k})$ . To předpokládá, že umístění robota  $\mathbf{x}_k$  je známo (nebo alespoň deterministické) po celou dobu, pod podmínkou znalosti počátečního umístění. Mapa  $\mathbf{m}$  se potom vytvoří spojením pozorování z různých míst. Naopak problém lokalizace může být formulován jako výpočet pravděpodobnostní distribuce  $p(\mathbf{x}_k \mid \mathbf{Z}_{0:k}, \mathbf{U}_{0:k}, \mathbf{m})$ . To předpokládá, že je známo umístění landmarků a cílem je vzhledem k nim vypočítat odhad umístění robota. Avšak model pozorování  $p(\mathbf{z}_k \mid \mathbf{x}_k, \mathbf{m})$  závisí jak na stavu robota, tak na umístění landmarků. Z toho vyplývá, že pravděpodobnostní hustota nelze takto rozdělit

$$p(\mathbf{x}_k, \mathbf{m} \mid \mathbf{z}_k) \neq p(\mathbf{x}_k \mid \mathbf{z}_k) p(\mathbf{m} \mid \mathbf{z}_k).$$

Takové rozdělení by vedlo k nekonzistentnosti odhadů a nepoužitelným výsledkům.

# 4 Graph-Based SLAM


## 4.1 Obecně

Při tomto přístupu se k ukládání dat používá graf. Uzel grafu reprezentuje stav robota a měření provedená z tohoto stavu. Hrany mezi uzly představují jejich vzájemnou polohu. Cílem algoritmu je najít takové rozložení uzlů, které minimalizuje čtvercovou chybu rozdílu pozorování a "virtuálního pozorování" [1]. Tím se získá nejlepší odhad mapy. Optimalizace neprobíhá po každém novém pozorování, čímž se Graph SLAM řadí mezi offline metody řešení.

Formulace SLAM pomocí grafu byla poprvé představena v roce 1997, avšak kvůli vysoké výpočetní náročnosti trvalo ještě několik let, než se začala používat v reálných aplikacích. V dnešní době patří Graph SLAM k nejmodernějším technikám, co se rychlosti a přesnosti týče.

## 4.2 Definice

Pro správný chod graph SLAMu musí fungovat souhra mezi jeho dvěma částmi front-end a back-end. Front-end se obecně stará o sestavení samotného grafu a back-end o jeho optimalizaci a tedy i optimalizaci mapy.




Obrázek 3: Schéma převzaté z [2] znázorňuje průchod dat metodou Graph SLAM. Surová data (pozorování, odometrie) nejdříve zpracuje front-end a vytvoří graf. Ten po daném okamžiku putuje do back-end, kde se optimalizací získá nejlepší odhad mapy prostředí a poté předá opět do první části.

- **Front-end** První část vytváří graf, kterým reprezentuje mapu prostředí. Každý uzel  $x_i$  obsahuje informaci o stavu robota a o pozorování provedeném z tohoto stavu v čase  $i$ . Hrana mezi sousedními uzly  $x_i$  a  $x_{i+1}$  odpovídá zaznamenané odometrii při pohybu robota. Pokud je hrana mezi různými uzly  $x_i$  a  $x_j$ , pak je to tzv. virtuální měření. To se zaznamená ve chvíli, kdy robot naměří podobná data (tzn. ocitne se ve stejné části prostředí) jako v některém z předešlých měření.

Využívá se scan matching, který porovnává dvě pozorování z uzlů  $x_i$  a  $x_j$  z různých časových okamžiků a v případě zjištění podobnosti je vypočítána relativní poloha uzlů  $x_i$  a  $x_j$ . To je ve skutečnosti transformace pozorování z  $x_i$  taková, aby se maximálně překrývalo s pozorováním uzlu  $x_j$ . Tuto transformaci nazýváme virtuálním pozorováním.

Znázornění problému je v obrázku 4, kde  $x_i$  je aktuální uzel,  $x_j$  je uzel, ve kterém bylo provedeno podobné pozorování jako to aktuální,  $\hat{z}_{ij}$  je predikce virtuálního měření reprezentující "jak uzel  $i$  vidí uzel  $j$ ",  $z_{ij}$  je virtuální měření,  $\Omega_{ij}$  je informační matice virtuálního měření a  $e_{ij}(x_i, x_j)$  je funkce, která vyjadřuje rozdíl virtuálního a predikovaného měření.





Obrázek 4: Znázornění virtuálního měření a jeho predikce [5].

- **Back-end**

## Reference

- [1] P. Abbeel. GraphSLAM. <https://people.eecs.berkeley.edu/~pabbeel/cs287-fa13/slides/GraphSLAM.pdf>, 11 2013. UC Berkeley EECS.
- [2] W. Burgard. Graph-based SLAM. <http://ais.informatik.uni-freiburg.de/teaching/ss18/robotics/slides/16-graph-slam.pdf>, 07 2018. UNI Freiburg.
- [3] C. Cadena, L. Carlone, H. Carrillo, Y. Latif, D. Scaramuzza, J. Neira, I. D. Reid, and J. J. Leonard. Simultaneous localization and mapping: Present, future, and the robust-perception age. *CoRR*, abs/1606.05830, 2016.
- [4] H. Durrant-Whyte and T. Bailey. Simultaneous localisation and mapping (slam): Part i the essential algorithms. *IEEE ROBOTICS AND AUTOMATION MAGAZINE*, 2006.
- [5] G. Grisetti, R. Kuemmerle, C. Stachniss, and W. Burgard. A tutorial on graph-based SLAM. *Intelligent Transportation Systems Magazine, IEEE*, 2(4):31–43, 2010.